

Prediksi Harga dan Segmentasi Properti Menggunakan Random Forest Regression dan K-Means

Steven Krisna Putra¹, Muhammad Nashrul Aziz²
Program Studi Sistem Informasi, Universitas Negeri Surabaya

¹24051214142@mhs.unesa.ac.id

²24051214159@mhs.unesa.ac.id

Abstrak— Perkembangan sektor properti yang semakin pesat menyebabkan kebutuhan akan informasi harga properti yang akurat menjadi semakin penting bagi calon pembeli, penjual, maupun investor. Penentuan harga properti dipengaruhi oleh berbagai faktor seperti dari kualitas bangunan, luas area hunian, kapasitas garasi, luas basement, dan tahun pembangunan. Penelitian ini bertujuan membangun model prediksi harga properti menggunakan algoritma Random Forest Regression dan melakukan segmentasi properti menggunakan K-Means Clustering dengan pendekatan Cross Industry Standard Process for Data Mining (CRISP-DM). Dataset yang digunakan adalah House Prices Dataset dari Kaggle yang terdiri atas 1.460 data properti. Lima fitur utama yang digunakan yaitu OverallQual, GrLivArea, GarageCars, TotalBsmtSF, dan YearBuilt, di mana OverallQual merupakan fitur dengan tingkat kepentingan tertinggi sebesar 58,25%. Hasil evaluasi menunjukkan bahwa Random Forest Regression menghasilkan MAE sebesar 19.182,22, RMSE sebesar 28.922,58, dan R² Score sebesar 0,89, mengungguli Linear Regression yang menghasilkan MAE sebesar 25.414,73, RMSE sebesar 39.763,30, dan R² Score sebesar 0,79. Pada tahap segmentasi, K-Means Clustering dengan Elbow Method menghasilkan tiga kluster optimal yaitu properti anggaran, properti kelas menengah, dan properti premium, dengan Silhouette Score sebesar 0,30. Model terbaik diimplementasikan dalam aplikasi web menggunakan Streamlit untuk mendukung prediksi harga dan analisis segmentasi properti secara interaktif.

Kata Kunci— Random Forest Regression, K-Means Clustering, Prediksi Harga Properti, CRISP-DM, Streamlit, Segmentasi Properti.

I. PENDAHULUAN

A. Latar Belakang

Perkembangan teknologi informasi dan meningkatnya ketersediaan data dalam skala besar telah mendorong pemanfaatan teknik Data Mining secara luas di berbagai sektor strategis, termasuk industri properti. Sektor properti memegang peran yang sangat penting dalam pertumbuhan ekonomi nasional karena berkaitan langsung dengan kebutuhan mendasar masyarakat akan tempat tinggal sekaligus menjadi instrumen investasi jangka panjang yang diminati oleh berbagai kalangan. Tingginya permintaan terhadap properti hunian mendorong dinamika harga yang terus berfluktuasi dan semakin kompleks dari waktu ke waktu. Kondisi ini menuntut adanya pendekatan yang lebih sistematis dan berbasis data dalam proses estimasi harga properti guna mengurangi ketidakpastian dalam transaksi di pasar properti [1].

Dalam praktiknya, penentuan harga properti dipengaruhi oleh berbagai faktor yang saling berinteraksi secara kompleks, seperti kualitas bangunan secara keseluruhan, luas area hunian di atas tanah, kapasitas garasi, luas basement, serta usia bangunan sejak pertama kali dibangun. Faktor-faktor tersebut tidak berdiri sendiri melainkan memiliki hubungan yang saling memengaruhi satu sama lain dalam membentuk nilai akhir sebuah properti. Kompleksitas hubungan nonlinier antar faktor tersebut menyebabkan proses estimasi harga secara manual oleh agen properti maupun pemilik rumah menjadi tidak efektif, tidak konsisten, dan rentan terhadap bias penilaian subjektif yang dapat merugikan salah satu pihak dalam transaksi [2].

Seiring dengan pesatnya perkembangan algoritma machine learning, berbagai penelitian telah mengeksplorasi penerapan teknik kecerdasan buatan untuk menyelesaikan permasalahan prediksi harga properti. Dibandingkan dengan metode statistik konvensional seperti Linear Regression yang mengasumsikan hubungan linier antar variabel, algoritma berbasis ensemble seperti Random Forest Regression terbukti mampu menangkap pola hubungan yang jauh lebih kompleks dan nonlinier dalam data properti [2][3]. Penelitian oleh Adetunji et al. (2022) yang dipublikasikan di *Procedia Computer Science* (Elsevier) secara eksplisit menunjukkan bahwa Random Forest Regression mampu menghasilkan nilai R² sebesar 0,9 dan RMSE sekitar 2,5 dalam memprediksi harga rumah, jauh melampaui performa model regresi konvensional yang dijadikan pembandingan [3]. Lebih lanjut, Limbong et al. (2025) dalam *Journal of Artificial Intelligence and Engineering Applications* membuktikan bahwa Random Forest secara konsisten mengungguli Linear Regression dalam keempat metrik evaluasi yaitu MAE, RMSE, R² Score, dan MAPE pada konteks prediksi harga properti [2].

Di sisi lain, pemahaman mendalam terhadap struktur dan karakteristik pasar properti juga menjadi kebutuhan yang tidak kalah penting, khususnya bagi pelaku bisnis, investor, maupun pengembang properti. Segmentasi properti berbasis pendekatan clustering memungkinkan pengelompokan properti ke dalam segmen-segmen yang memiliki kesamaan karakteristik, sehingga memudahkan proses analisis pasar, identifikasi segmen target, dan pengambilan keputusan bisnis yang lebih terarah. K-Means Clustering merupakan salah satu algoritma unsupervised learning yang paling banyak digunakan untuk keperluan tersebut karena proses komputasinya yang efisien dan hasil pengelompokannya yang mudah diinterpretasikan [5]. Penelitian Amin et al. (2024) yang diterbitkan di *PeerJ Computer Science* membuktikan bahwa K-Means Clustering berhasil mengklasifikasikan lebih

dari 12.000 data listing properti ke dalam kluster-kluster yang terdistinkt dengan baik menggunakan Silhouette Coefficient, Calinski-Harabasz Index, dan Davies-Bouldin Index sebagai metrik evaluasi kualitas kluster [5].

Dataset yang digunakan dalam penelitian ini adalah House Prices: Advanced Regression Techniques yang tersedia secara publik pada platform Kaggle. Dataset ini memuat 1.460 data properti dengan berbagai atribut yang mencerminkan karakteristik fisik dan kondisi bangunan. Penelitian oleh Yu (2023) yang diterbitkan melalui Atlantis Press menganalisis dataset yang sama dan menemukan bahwa variabel OverallQual, GrLivArea, TotalBsmtSF, dan YearBuilt memiliki korelasi positif yang signifikan terhadap SalePrice, menjadikan kelima fitur tersebut sebagai prediktor utama yang relevan dalam pemodelan harga properti [4].

Proses pengembangan model dalam penelitian ini mengadopsi metodologi Cross Industry Standard Process for Data Mining (CRISP-DM) yang terdiri atas enam tahapan terstruktur yaitu Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation, dan Deployment. Shimaoka et al. (2024) dalam SBC Computing Reviews menegaskan bahwa CRISP-DM tetap menjadi standar de facto yang paling banyak digunakan dalam proyek Data Science di seluruh dunia, mengingat 82% tim data science gagal memberikan nilai optimal karena tidak menggunakan model proses yang terstandarisasi dan sistematis [7]. Dengan mengikuti kerangka kerja ini secara konsisten, pengembangan model diharapkan dapat dilakukan dengan lebih terstruktur, reproduktibel, dan bernilai guna tinggi.

Sebagai bentuk implementasi akhir, model prediksi dan segmentasi properti yang dihasilkan dalam penelitian ini akan diintegrasikan ke dalam sebuah aplikasi web interaktif menggunakan framework Streamlit. Pendekatan deployment berbasis web ini dipilih agar sistem dapat diakses dan dimanfaatkan secara langsung oleh pengguna akhir, termasuk calon pembeli, penjual, investor, maupun pelaku bisnis properti, tanpa memerlukan pengetahuan teknis di bidang pemrograman atau data science [9][10].

B. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan secara komprehensif di atas, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana membangun model prediksi harga properti yang optimal menggunakan algoritma Random Forest Regression berdasarkan dataset House Prices dari Kaggle?
2. Bagaimana melakukan segmentasi properti menggunakan algoritma K-Means Clustering untuk mengidentifikasi kelompok properti berdasarkan karakteristiknya?
3. Bagaimana perbandingan performa antara model Random Forest Regression dan Linear Regression dalam memprediksi harga properti berdasarkan metrik evaluasi MAE, RMSE, dan R^2 Score?
4. Bagaimana mengimplementasikan model prediksi dan segmentasi properti ke dalam aplikasi web interaktif berbasis Streamlit?

C. Tujuan Penelitian

Berdasarkan rumusan masalah yang telah ditetapkan, tujuan yang ingin dicapai dalam penelitian ini adalah:

1. Membangun model prediksi harga properti yang akurat menggunakan algoritma Random Forest Regression dengan memanfaatkan lima fitur utama dari dataset House Prices Kaggle.
2. Melakukan segmentasi properti ke dalam kluster-kluster yang representatif menggunakan algoritma K-Means Clustering berdasarkan karakteristik fisik properti.
3. Membandingkan performa model Linear Regression dan Random Forest Regression secara kuantitatif berdasarkan metrik evaluasi MAE, RMSE, dan R^2 Score.
4. Mengimplementasikan model terbaik yang dihasilkan ke dalam aplikasi web interaktif berbasis Streamlit sebagai bentuk deployment yang dapat digunakan secara langsung oleh pengguna.

D. Batasan Masalah

Agar penelitian ini terfokus dan dapat dilaksanakan secara sistematis, maka ditetapkan batasan-batasan masalah sebagai berikut:

1. Dataset yang digunakan terbatas pada House Prices Dataset yang diperoleh dari platform Kaggle dengan jumlah 1.460 data properti.
2. Fitur yang digunakan dalam pemodelan prediksi harga dibatasi pada lima fitur utama yaitu OverallQual, GrLivArea, GarageCars, TotalBsmtSF, dan YearBuilt.
3. Algoritma yang dibandingkan dalam tahap prediksi terbatas pada Linear Regression sebagai baseline model dan Random Forest Regression sebagai model utama.
4. Segmentasi properti dilakukan menggunakan algoritma K-Means Clustering dengan penentuan jumlah kluster optimal berdasarkan Elbow Method dan evaluasi menggunakan Silhouette Score.
5. Implementasi sistem dilakukan menggunakan framework Streamlit berbasis Python dan tidak mencakup pengembangan aplikasi mobile.

E. Manfaat

1. Manfaat Praktis: Penelitian ini diharapkan dapat membantu calon pembeli, penjual, dan investor properti dalam memperoleh estimasi harga yang lebih objektif, akurat, dan berbasis data dibandingkan penilaian manual yang rentan terhadap subjektivitas. Hasil segmentasi properti juga dapat dimanfaatkan oleh pelaku bisnis sebagai dasar analisis pasar dan identifikasi segmen target yang lebih terarah. Selain itu, aplikasi web berbasis Streamlit yang dihasilkan dapat digunakan secara langsung sebagai alat bantu pengambilan keputusan dalam transaksi properti.
2. Manfaat Akademis: Penelitian ini diharapkan dapat menjadi referensi ilmiah bagi peneliti selanjutnya yang berminat mengembangkan studi tentang penerapan Random Forest Regression dan K-Means Clustering dalam domain properti. Selain itu, penelitian ini dapat menjadi contoh penerapan metodologi CRISP-DM secara menyeluruh dan terstruktur dalam siklus pengembangan

proyek Data Mining, mulai dari tahap pemahaman bisnis hingga deployment sistem yang dapat digunakan pengguna akhir.

II. TINJAUAN PUSTAKA

A. Data Mining

Data Mining merupakan proses komputasi yang bertujuan menemukan pola, hubungan, anomali, dan informasi tersembunyi yang bernilai tinggi dari kumpulan data berukuran besar melalui penerapan teknik statistik, machine learning, dan kecerdasan buatan. Proses ini pada dasarnya merupakan bagian inti dari siklus Knowledge Discovery in Databases (KDD) yang mencakup serangkaian tahapan mulai dari seleksi data, preprocessing, transformasi, data mining itu sendiri, hingga interpretasi dan evaluasi pola yang ditemukan [7]. Tujuan utama Data Mining adalah mengubah data mentah yang tidak terstruktur menjadi pengetahuan yang dapat diinterpretasikan dan digunakan secara langsung untuk mendukung proses pengambilan keputusan di berbagai domain.

Secara umum, tugas-tugas utama dalam Data Mining dapat dikategorikan ke dalam dua kelompok besar, yaitu tugas deskriptif dan tugas prediktif. Tugas deskriptif mencakup clustering, association rule mining, dan anomaly detection yang bertujuan untuk menggambarkan pola dan struktur yang ada dalam data. Sementara itu, tugas prediktif mencakup klasifikasi dan regresi yang bertujuan untuk membangun model prediksi berdasarkan data historis yang telah tersedia [7]. Dalam penelitian ini, pendekatan regresi digunakan untuk membangun model prediksi harga properti, sedangkan pendekatan clustering digunakan untuk melakukan segmentasi properti berdasarkan kemiripan karakteristiknya.

Penerapan Data Mining dalam sektor properti telah berkembang pesat seiring meningkatnya ketersediaan dataset properti secara publik di berbagai platform seperti Kaggle. Berbagai penelitian menunjukkan bahwa teknik Data Mining mampu menghasilkan model yang jauh lebih akurat dan dapat diandalkan dibandingkan metode penilaian properti konvensional, karena mampu mengidentifikasi pola tersembunyi dalam hubungan antara atribut fisik properti dengan harga jualnya [3][4].

B. Cross Industry Standard Process for Data Mining (CRISP-DM)

CRISP-DM merupakan metodologi standar yang paling banyak digunakan secara global dalam pengembangan proyek Data Mining dan Data Science. Metodologi ini dirancang untuk memberikan kerangka kerja yang sistematis, fleksibel, dan bersifat independen terhadap jenis industri maupun platform teknologi yang digunakan, sehingga dapat diterapkan di berbagai domain dan skala proyek yang berbeda [7]. Shimaoka et al. (2024) dalam kajian evolusi CRISP-DM yang dipublikasikan di SBC Computing Reviews menegaskan bahwa metodologi ini tetap relevan dan terus berkembang untuk menyesuaikan diri dengan kompleksitas proyek Data Science modern. Kajian tersebut menemukan bahwa ekspansi proyek Data Science di berbagai organisasi didorong oleh tiga faktor utama yaitu pertumbuhan volume data, peningkatan

kapasitas penyimpanan, dan kemajuan kemampuan komputasi, namun 82% tim masih gagal memberikan nilai optimal karena tidak menggunakan model proses yang terstandarisasi [7].

CRISP-DM terdiri atas enam tahapan utama yang saling berkaitan dan bersifat iteratif sebagai berikut:

1. **Data Understanding:** Tahap ini mencakup proses pengumpulan data awal, eksplorasi karakteristik dan distribusi data, identifikasi masalah kualitas data, serta penemuan wawasan awal yang dapat membentuk hipotesis penelitian. Exploratory Data Analysis (EDA) dilakukan pada tahap ini untuk memahami distribusi setiap fitur, korelasi antar variabel, serta mengidentifikasi potensi masalah seperti missing value dan outlier.
2. **Data Preparation:** Tahap ini melibatkan serangkaian proses transformasi data mentah menjadi dataset yang siap digunakan untuk pemodelan, termasuk penanganan missing value, seleksi fitur yang relevan, pembagian data menjadi data latih dan data uji, serta standarisasi data agar setiap fitur memiliki skala yang sebanding.
3. **Modeling:** Pada tahap ini dilakukan pembangunan model menggunakan algoritma yang telah dipilih, yaitu Linear Regression sebagai baseline model dan Random Forest Regression sebagai model utama untuk prediksi harga, serta K-Means Clustering untuk segmentasi properti. Setiap algoritma dikonfigurasi dengan parameter yang optimal melalui proses tuning yang sistematis.
4. **Evaluation:** Tahap ini bertujuan untuk mengevaluasi kualitas dan performa model yang dihasilkan berdasarkan metrik evaluasi yang relevan. Untuk model regresi digunakan metrik MAE, RMSE, dan R^2 Score, sedangkan untuk model clustering digunakan Silhouette Score sebagai ukuran kualitas pengelompokan yang dihasilkan.
5. **Deployment:** Tahap terakhir ini mencakup implementasi model terbaik ke dalam sistem yang dapat diakses dan digunakan oleh pengguna akhir secara langsung. Dalam penelitian ini, deployment dilakukan dalam bentuk aplikasi web interaktif menggunakan framework Streamlit.

C. Random Forest Regression

Random Forest Regression merupakan algoritma machine learning yang termasuk dalam kategori ensemble learning, yaitu pendekatan yang menggabungkan prediksi dari sejumlah model dasar (base learner) untuk menghasilkan prediksi akhir yang lebih akurat dan stabil dibandingkan model tunggal [3]. Secara spesifik, Random Forest membangun sejumlah decision tree secara paralel menggunakan teknik bootstrap aggregating (bagging), di mana setiap tree dilatih menggunakan subset data yang diambil secara acak dengan pengembalian dari data latih. Selain sampling pada data, Random Forest juga menerapkan random feature selection di setiap node pemisahan, sehingga setiap tree yang dibangun memiliki karakteristik yang berbeda-beda dan saling melengkapi dalam menghasilkan prediksi [3].

Prediksi akhir pada Random Forest Regression diperoleh dengan cara merata-ratakan prediksi dari seluruh decision tree

yang telah dibangun, sebagaimana dinyatakan dalam persamaan berikut:

$$\hat{y} = \frac{1}{B} \sum_{b=1}^B f_{b(x)} \dots (1)$$

di mana $\hat{y}$ adalah nilai prediksi akhir, B adalah jumlah decision tree yang dibangun, dan $f_{b(x)}$ adalah prediksi dari tree ke-b untuk input x. Pendekatan averaging ini secara efektif mereduksi varians prediksi tanpa meningkatkan bias, sehingga model yang dihasilkan memiliki kemampuan generalisasi yang lebih baik terhadap data yang belum pernah dilihat sebelumnya [3].

Adetunji et al. (2022) dalam penelitian yang dipublikasikan di Procedia Computer Science membuktikan secara empiris bahwa Random Forest Regression menghasilkan nilai $R^2=0,9$ dan $RMSE \approx 2,5$ dalam memprediksi harga rumah, mengungguli performa Linear Regression, Support Vector Regression, dan Decision Tree Regression [3]. Pada dataset House Prices Kaggle yang digunakan dalam penelitian ini, Yu (2023) juga mengkonfirmasi bahwa fitur OverallQual, GrLivArea, TotalBsmtSF, dan YearBuilt memiliki korelasi positif yang paling signifikan terhadap SalePrice, sehingga menjadi fitur-fitur utama yang direkomendasikan dalam pemodelan [4].

Keunggulan utama Random Forest Regression yang relevan dengan penelitian ini antara lain: (1) kemampuan menangani hubungan nonlinier yang kompleks antar variabel prediktor dan variabel target; (2) ketahanan yang tinggi terhadap overfitting berkat mekanisme bagging dan random feature selection; (3) kemampuan menangani dataset dengan jumlah fitur yang relatif banyak tanpa memerlukan seleksi fitur yang ekstensif; serta (4) penyediaan informasi feature importance yang memungkinkan interpretasi kontribusi setiap fitur terhadap hasil prediksi secara kuantitatif [3][4].

D. Linear Regression

Linear Regression merupakan salah satu metode statistik tertua dan paling banyak digunakan untuk memodelkan hubungan antara satu atau lebih variabel independen dengan variabel dependen yang bersifat kontinu [8]. Dalam konteks prediksi harga properti, Linear Regression berasumsi bahwa terdapat hubungan linier antara fitur-fitur properti seperti luas bangunan dan kualitas konstruksi dengan harga jualnya. Model Linear Regression multivariat dapat dinyatakan dalam persamaan berikut:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + \epsilon \dots (2)$$

di mana $\hat{y}$ adalah nilai prediksi harga properti, β_0 adalah konstanta intercept, β_1 hingga β_n adalah koefisien regresi untuk masing-masing fitur, x_1 hingga x_n adalah nilai fitur-fitur yang digunakan, dan ϵ adalah residual error yang mencerminkan selisih antara nilai prediksi dengan nilai aktual. Koefisien regresi diestimasi menggunakan metode Ordinary

Least Squares (OLS) yang meminimalkan jumlah kuadrat residual error secara keseluruhan [8].

Meskipun memiliki implementasi yang sederhana dan hasil yang mudah diinterpretasikan, Linear Regression memiliki keterbatasan mendasar dalam menangani data properti yang seringkali memiliki hubungan nonlinier antar variabelnya. Hakim et al. (2025) dalam ALPHA: Journal of Science and Technology menyatakan bahwa meskipun Linear Regression mampu memberikan estimasi yang cukup baik pada dataset berdistribusi linier, performanya secara konsisten lebih rendah dibandingkan model ensemble dalam menangani data properti yang kompleks [8]. Temuan ini diperkuat oleh Limbong et al. (2025) dalam JAIEA yang secara langsung membuktikan bahwa Random Forest mengungguli Linear Regression dalam semua metrik evaluasi pada permasalahan prediksi harga properti [2]. Dalam penelitian ini, Linear Regression diposisikan sebagai baseline model untuk menjadi acuan pembandingan performa Random Forest Regression.

E. K-Means Clustering

K-Means Clustering merupakan algoritma unsupervised learning yang paling banyak digunakan untuk mengelompokkan data ke dalam K kluster berdasarkan kemiripan karakteristik antar objek [5]. Algoritma ini bekerja secara iteratif melalui dua tahap utama yang dilakukan secara bergantian hingga konvergensi tercapai, yaitu: (1) tahap assignment, di mana setiap titik data ditetapkan ke kluster dengan centroid terdekat berdasarkan jarak Euclidean; dan (2) tahap update, di mana posisi centroid setiap kluster diperbarui dengan menghitung rata-rata dari seluruh titik data yang tergabung dalam kluster tersebut [5][6].

Secara matematis, algoritma K-Means bertujuan untuk meminimalkan fungsi objektif Within-Cluster Sum of Squares (WCSS) yang didefinisikan sebagai berikut:

$$J = \sum_{i=1}^K \sum_{x \in S_i} ||x - \mu_i||^2 \dots (3)$$

di mana K adalah jumlah kluster, S_i adalah himpunan titik data yang tergabung dalam kluster ke-i, μ_i adalah centroid dari

kluster ke-i, dan $||x - \mu_i||^2$ adalah kuadrat jarak Euclidean antara titik data x dengan centroid μ_i . Minimisasi fungsi ini dilakukan secara iteratif hingga tidak ada lagi perpindahan titik data antar kluster yang menghasilkan penurunan nilai WCSS [5].

Penentuan jumlah kluster K yang optimal merupakan tantangan utama dalam penerapan K-Means Clustering karena nilai K tidak dapat ditentukan secara otomatis oleh algoritma itu sendiri. Dua metode yang paling umum digunakan untuk menentukan K optimal adalah Elbow Method dan Silhouette Score. Elbow Method bekerja dengan memplot nilai WCSS terhadap berbagai nilai K dan mencari titik "siku" (elbow) yang menandai penurunan nilai WCSS yang paling signifikan. Sedangkan Silhouette Score mengukur seberapa mirip setiap titik data dengan klasternya sendiri dibandingkan dengan kluster terdekat lainnya, dengan nilai berkisar antara -1 hingga +1 di mana nilai mendekati +1 mengindikasikan

pengelompokan yang baik [6]. Punhani et al. (2022) dalam IEEE Access menegaskan bahwa kombinasi Elbow Method dan Silhouette Coefficient merupakan pendekatan paling andal untuk menentukan nilai K yang optimal dalam berbagai konteks penerapan K-Means [6].

Dalam konteks segmentasi properti, Amin et al. (2024) dalam PeerJ Computer Science berhasil mengimplementasikan K-Means Clustering untuk mengklasifikasikan lebih dari 12.000 data listing properti ke dalam kluster-kluster yang terdistinkt menggunakan tiga metrik evaluasi sekaligus yaitu Silhouette Coefficient, Calinski-Harabasz Index, dan Davies-Bouldin Index, menunjukkan bahwa K-Means merupakan pilihan yang sangat efektif untuk segmentasi data properti berskala besar [5].

F. Matriks Evaluasi

Evaluasi performa model merupakan komponen kritis dalam pengembangan sistem prediksi dan clustering yang andal. Dalam penelitian ini digunakan empat metrik evaluasi utama yang secara luas diakui dalam komunitas data mining dan machine learning.

1. Mean Absolute Error (MAE): MAE mengukur rata-rata nilai absolut selisih antara nilai prediksi dengan nilai aktual, sehingga memberikan gambaran seberapa besar kesalahan prediksi secara rata-rata dalam satuan yang sama dengan variabel target. MAE diformulasikan sebagai:

$$MAE = \left(\frac{1}{n}\right) \sum_{i=1}^n |y_i - \hat{y}_i| \dots (4)$$

di mana n adalah jumlah sampel, y_i adalah nilai aktual, dan $\hat{y}_i$ adalah nilai prediksi. Semakin kecil nilai MAE, semakin baik performa model prediksi.

2. Root Mean Square Error (RMSE): RMSE mengukur akar kuadrat dari rata-rata kuadrat selisih antara nilai prediksi dan nilai aktual. Berbeda dengan MAE, RMSE memberikan penalti yang lebih besar terhadap kesalahan prediksi yang besar karena adanya operasi kuadrat. RMSE diformulasikan sebagai:

$$RMSE = \sqrt{\left(\frac{1}{n}\right) \sum_{i=1}^n (y_i - \hat{y}_i)^2} \dots (5)$$

3. R^2 Score (Coefficient of Determination): R^2 Score mengukur proporsi variansi dalam variabel target yang berhasil dijelaskan oleh model, dengan nilai berkisar antara 0 hingga 1 di mana nilai mendekati 1 mengindikasikan model yang sangat baik. R^2 diformulasikan sebagai:

$$R^2 = 1 - \frac{\sum_i (y_i - \bar{y})^2}{\sum_i (y_i - \hat{y}_i)^2} \dots (6)$$

di mana $\bar{y}$ adalah rata-rata nilai aktual.

4. Silhouette Score: Silhouette Score digunakan untuk mengevaluasi kualitas kluster yang dihasilkan oleh K-Means Clustering. Nilai Silhouette untuk setiap titik data dihitung berdasarkan perbandingan antara jarak rata-rata titik tersebut terhadap titik-titik lain dalam

klasternya sendiri (cohesion) dengan jarak rata-rata terhadap titik-titik dalam kluster terdekat (separation). Silhouette Score rata-rata diformulasikan sebagai:

$$S = \frac{(b-a)}{\max(a,b)} \dots (7)$$

di mana a adalah rata-rata jarak intra-kluster dan b adalah rata-rata jarak ke kluster terdekat. Nilai mendekati +1 menunjukkan kluster yang terdefinisi dengan baik [6].

G. Streamlit

Streamlit merupakan framework open-source berbasis Python yang dirancang khusus untuk memudahkan pengembang dan ilmuwan data dalam membangun aplikasi web interaktif secara cepat tanpa memerlukan keahlian dalam pengembangan frontend seperti HTML, CSS, maupun JavaScript. Framework ini memungkinkan integrasi langsung antara kode Python untuk pemrosesan data dan model machine learning dengan antarmuka web yang dapat diakses melalui browser standar. Streamlit menyediakan berbagai komponen interaktif bawaan seperti slider, dropdown, text input, dan visualisasi grafik yang dapat dikonfigurasi dengan sangat sedikit baris kode, sehingga mempercepat proses prototyping dan deployment sistem berbasis data secara signifikan [9].

Fauzi et al. (2025) dalam RIGGS: Journal of Artificial Intelligence and Digital Business menerapkan Streamlit sebagai media deployment sistem prediksi harga properti di Indonesia berbasis Random Forest dan membuktikan bahwa Streamlit mampu menghasilkan antarmuka yang intuitif dan responsif untuk digunakan oleh pengguna akhir [9]. Emilita et al. (2026) dalam Jurnal Minfo Polgan juga menggunakan Streamlit untuk mengimplementasikan model prediksi harga properti berbasis Random Forest di Jakarta Selatan, dan menyimpulkan bahwa Streamlit merupakan pilihan yang sangat tepat untuk deployment model machine learning dalam konteks aplikasi properti berbasis web [10].

H. Penelitian Terdahulu

Penelitian mengenai prediksi harga properti dan segmentasi berbasis machine learning telah berkembang dengan pesat dalam lima tahun terakhir. Rangkuman penelitian terdahulu yang relevan disajikan pada Tabel 1 berikut.

TABEL 1
PERBANDINGAN PENELITIAN TERDAHULU

No	Peneliti (Tahun)	Metode	Dataset	Hasil Terbaik
1	Adetunji et al. (2022) [3]	Random Forest, Linear Regression, SVM, Decision Tree	Boston Housing	RF: $R^2=0,9$, RMSE $\approx 2,5$
2	Yu (2023) [4]	Korelasi Pearson, Random Forest	Kaggle House Prices	OverallQual, GrLivArea, TotalBsmtSF, YearBuilt


				sebagai fitur utama
3	Limbong et al. (2025) [2]	Linear Regression, Random Forest	Dataset Harga Rumah	RF unggul di MAE, RMSE, R^2 , MAPE
4	Amin et al. (2024) [5]	K-Means Clustering	12.000+ listing properti	Klaster optimal dengan Silhouette Coefficient
5	Punhani et al. (2022) [6]	K-Means, Silhouette, Elbow	Berbagai dataset	Kombinasi Elbow + Silhouette paling andal untuk K optimal
6	Wardani et al. (2024) [1]	Random Forest	Data properti Surabaya	Dimensi tanah & bangunan sebagai fitur dominan
7	Fauzi et al. (2025) [9]	Random Forest + Streamlit	Data properti Indonesia	Sistem prediksi berbasis web yang interaktif

Berdasarkan kajian terhadap penelitian-penelitian terdahulu tersebut, dapat diidentifikasi bahwa terdapat celah penelitian (research gap) yang belum banyak ditangani, yaitu integrasi antara sistem prediksi harga berbasis Random Forest Regression dengan segmentasi properti berbasis K-Means Clustering dalam satu sistem terpadu yang dapat diakses secara interaktif melalui antarmuka web. Penelitian ini hadir untuk mengisi celah tersebut dengan menggabungkan kedua pendekatan dalam satu pipeline yang dikembangkan menggunakan metodologi CRISP-DM secara komprehensif dan diimplementasikan dalam aplikasi web berbasis Streamlit.

III. METODOLOGI

Penelitian ini mengadopsi metodologi Cross Industry Standard Process for Data Mining (CRISP-DM) yang terdiri atas enam tahapan terstruktur dan iteratif. Alur metodologi penelitian secara keseluruhan digambarkan pada Gbr 1. Alur Metodologi CRISP-DM

Gbr 1. Alur Metodologi CRISP-DM



A. Business Understanding

Tahap Business Understanding bertujuan untuk memahami permasalahan dan kebutuhan yang ingin diselesaikan melalui pendekatan berbasis data. Dalam penelitian ini, permasalahan utama yang diidentifikasi adalah ketidakakuratan estimasi harga properti secara manual akibat kompleksitas hubungan antar faktor penentu harga, serta belum tersedianya sistem segmentasi properti yang dapat membantu pelaku pasar dalam memahami karakteristik kelompok properti secara otomatis dan interaktif.

Berdasarkan identifikasi permasalahan tersebut, ditetapkan dua tujuan analitik utama dalam penelitian ini, yaitu: (1) membangun model prediksi harga properti yang akurat menggunakan algoritma Random Forest Regression dengan Linear Regression sebagai model pembanding; dan (2) melakukan segmentasi properti ke dalam klaster-klaster yang representatif menggunakan algoritma K-Means Clustering. Kriteria keberhasilan penelitian diukur berdasarkan nilai MAE, RMSE, dan R^2 Score untuk model regresi, serta Silhouette Score untuk model clustering. Hasil akhir penelitian diimplementasikan dalam bentuk aplikasi web interaktif berbasis Streamlit yang dapat digunakan langsung oleh pengguna akhir.

B. Data Understanding

1. Deskripsi Dataset

Dataset yang digunakan dalam penelitian ini adalah House Prices: Advanced Regression Techniques yang diperoleh secara publik dari platform Kaggle. Dataset ini terdiri atas 1.460 baris data properti dengan 81 kolom atribut yang mencerminkan berbagai karakteristik fisik, kondisi, dan lokasi properti perumahan, termasuk variabel target SalePrice yang merepresentasikan harga jual properti dalam satuan dolar Amerika Serikat. Dataset ini secara luas digunakan sebagai benchmark dalam penelitian prediksi harga properti berbasis machine learning [4].

2. Exploratory Data Analysis

Tahap EDA dilakukan untuk memperoleh pemahaman mendalam terhadap karakteristik dan distribusi data sebelum dilakukan pemodelan. Analisis pertama yang dilakukan adalah memeriksa distribusi variabel target

SalePrice. Hasil analisis menunjukkan bahwa distribusi SalePrice bersifat right-skewed dengan nilai mean sebesar \$180.921 dan median sebesar \$163.000, mengindikasikan adanya sejumlah properti dengan harga sangat tinggi yang memengaruhi rata-rata secara signifikan.

Analisis korelasi dilakukan menggunakan heatmap untuk mengidentifikasi hubungan antar variabel numerik. Hasil analisis korelasi menunjukkan bahwa variabel OverallQual, GrLivArea, GarageCars, TotalBsmtSF, dan YearBuilt memiliki korelasi positif yang paling signifikan terhadap SalePrice. Hubungan positif antara GrLivArea dan SalePrice serta OverallQual dan SalePrice dikonfirmasi lebih lanjut melalui visualisasi scatter plot, yang menunjukkan pola hubungan yang konsisten dan searah antara kedua variabel tersebut dengan harga jual properti.

Analisis missing value menunjukkan bahwa terdapat 19 kolom yang memiliki data yang hilang. Empat kolom dengan persentase missing value yang sangat tinggi diidentifikasi yaitu PoolQC (99,52%), MiscFeature (96,30%), Alley (93,77%), dan Fence (80,75%), yang mengindikasikan bahwa kolom-kolom tersebut tidak relevan untuk dipertahankan dalam proses pemodelan.

C. Data Preparation

Tahap Data Preparation merupakan serangkaian proses transformasi dan pembersihan data mentah menjadi dataset yang siap digunakan untuk pemodelan. Proses ini dilaksanakan melalui empat langkah utama sebagai berikut.

1. Penghapusan Kolom dengan Missing Value Tinggi

Empat kolom yang memiliki persentase missing value sangat tinggi dan tidak relevan secara analitik dihapus dari dataset, yaitu PoolQC, Alley, Fence, dan MiscFeature. Setelah penghapusan keempat kolom tersebut, dimensi dataset berkurang dari 81 menjadi 77 kolom dengan jumlah baris tetap sebesar 1.460 data, sebagaimana ditunjukkan pada Tabel II.

TABEL II
DIMENSI DATASET SETELAH PENGHAPUSAN KOLOM

Kondisi	Jumlah Baris	Jumlah Kolom
Sebelum pembersihan	1.460	81
Setelah penghapusan kolom	1.460	77


2. Penanganan Missing Value

Setelah penghapusan kolom dengan missing value tinggi, masih terdapat missing value pada kolom-kolom yang tersisa. Strategi imputasi yang diterapkan dibedakan berdasarkan tipe data kolom. Untuk kolom numerik yaitu LotFrontage, MasVnrArea, dan GarageYrBlt, missing value diisi menggunakan nilai median masing-masing kolom karena median lebih robust terhadap pengaruh outlier dibandingkan mean. Nilai median yang digunakan masing-masing adalah 69,0 untuk LotFrontage, 0,0 untuk

MasVnrArea, dan 1980,0 untuk GarageYrBlt. Untuk kolom kategorikal yang memiliki missing value seperti MasVnrType, BsmtQual, BsmtCond, BsmtExposure, BsmtFinType1, BsmtFinType2, Electrical, FireplaceQu, GarageType, GarageFinish, GarageQual, dan GarageCond, missing value diisi menggunakan modus (nilai yang paling sering muncul) pada masing-masing kolom.

3. Seleksi Fitur

Berdasarkan hasil analisis korelasi pada tahap EDA, seleksi fitur dilakukan untuk memilih variabel-variabel yang paling relevan dan memiliki korelasi tertinggi terhadap variabel target SalePrice.



Lima fitur utama yang dipilih untuk tahap pemodelan adalah OverallQual (kualitas keseluruhan bangunan), GrLivArea (luas area hunian di atas tanah dalam satuan kaki persegi), GarageCars (kapasitas garasi dalam satuan jumlah kendaraan), TotalBsmtSF (total luas basement dalam satuan kaki persegi), dan YearBuilt (tahun pembangunan properti). Seleksi lima fitur ini menghasilkan matriks fitur X berukuran (1.460, 5) dengan variabel target y berupa kolom SalePrice berukuran (1.460,).

Untuk kebutuhan clustering, fitur yang digunakan sedikit berbeda dari fitur prediksi. Fitur clustering mencakup SalePrice, GrLivArea, OverallQual, GarageCars, dan TotalBsmtSF dengan pertimbangan bahwa SalePrice diikutsertakan sebagai salah satu dimensi pengelompokan agar klaster yang terbentuk merepresentasikan segmen pasar properti secara lebih komprehensif.

4. Train Test Split

Dataset dibagi menjadi data latih dan data uji menggunakan fungsi train_test_split dari library scikit-learn dengan proporsi 80:20 dan parameter random_state=42 untuk memastikan reproduktibilitas hasil. Pembagian ini menghasilkan 1.168 data latih dan 292 data uji sebagaimana ditunjukkan pada Tabel III.

TABEL III
DISTRIBUSI DATA LATIH DAN DATA UJI

Subset	Jumlah Data	Proporsi
Data Latih (X _{train})	1.168	80%
Data Uji (X _{test})	292	20%
Total	1.460	100%

5. Standardisasi Data

Standardisasi data dilakukan menggunakan StandardScaler dari scikit-learn yang mentransformasi setiap fitur sehingga memiliki nilai mean=0 dan standar deviasi=1, sesuai dengan persamaan berikut:

$$z = \frac{(x-\mu)}{\sigma} \dots (8)$$

di mana z adalah nilai hasil standardisasi, x adalah nilai asli, μ adalah rata-rata fitur, dan σ adalah standar deviasi fitur. StandardScaler di-fit hanya pada data latih (X_{train}) kemudian diterapkan secara terpisah pada data uji (X_{test}) untuk menghindari data leakage. Standardisasi ini sangat penting khususnya untuk algoritma K-Means Clustering yang sensitif terhadap perbedaan skala antar fitur, karena algoritma ini menggunakan jarak Euclidean sebagai ukuran kemiripan antar titik data [6].

D. Modeling

Tahap pemodelan dilakukan dalam dua kelompok besar, yaitu pemodelan regresi untuk prediksi harga properti dan pemodelan clustering untuk segmentasi properti.

1. Linear Regression

Linear Regression diimplementasikan menggunakan kelas LinearRegression dari library scikit-learn sebagai baseline model. Model dilatih menggunakan data latih yang telah distandarisasi (X_{train_scaled}) dengan variabel target y_{train}. Tidak ada konfigurasi hyperparameter khusus yang diterapkan sehingga model menggunakan parameter default scikit-learn, yaitu fit_intercept=True dan metode estimasi Ordinary Least Squares (OLS). Proses pelatihan menghasilkan model linier yang kemudian digunakan untuk memprediksi SalePrice pada data uji (X_{test_scaled}).

2. Random Forest Regression

Random Forest Regression diimplementasikan menggunakan kelas RandomForestRegressor dari library scikit-learn sebagai model utama. Model dikonfigurasi dengan parameter random_state=42 untuk memastikan reproduktibilitas hasil, sedangkan parameter lainnya menggunakan nilai default scikit-learn yang meliputi n_estimators=100 (jumlah decision tree yang dibangun), max_features='auto', dan bootstrap=True. Model dilatih menggunakan data latih yang telah distandarisasi (X_{train_scaled}) dengan variabel target y_{train}. Setelah pelatihan selesai, model digunakan untuk memprediksi SalePrice pada data uji (X_{test_scaled}) dan menghasilkan

informasi feature importance yang menggambarkan kontribusi relatif setiap fitur terhadap akurasi prediksi.

3. K-Means Clustering

K-Means Clustering dilakukan dalam dua tahap. Tahap pertama adalah penentuan jumlah kluster optimal menggunakan Elbow Method, di mana nilai WCSS dihitung untuk berbagai nilai K mulai dari K=1 hingga K=10 menggunakan algoritma inisialisasi k-means++. Hasil perhitungan WCSS diplot terhadap nilai K untuk mengidentifikasi titik siku (elbow) yang menandai jumlah kluster optimal. Berdasarkan hasil Elbow Method, nilai K=3 dipilih sebagai jumlah kluster optimal karena pada titik tersebut penurunan nilai WCSS mulai melandai secara signifikan.

Tahap kedua adalah pembangunan model K-Means dengan K=3 menggunakan konfigurasi sebagai berikut: n_clusters=3, init='k-means++', random_state=42, dan n_init=10. Parameter init='k-means++' digunakan untuk menginisialisasi centroid secara cerdas guna mempercepat konvergensi dan mengurangi risiko terjebak pada solusi lokal yang suboptimal. Parameter n_init=10 menyatakan bahwa algoritma dijalankan sebanyak 10 kali dengan inisialisasi centroid yang berbeda-beda, dan hasil terbaik dipilih sebagai model final. Model dilatih menggunakan seluruh data clustering yang telah distandarisasi (X_{clustering_scaled}) berukuran (1.460, 5).

E. Evaluation

1. Evaluasi Model Regresi: Evaluasi performa model regresi dilakukan menggunakan tiga metrik yaitu MAE, RMSE, dan R² Score yang dihitung berdasarkan perbandingan antara nilai prediksi model (y_{pred}) dengan nilai aktual SalePrice pada data uji (y_{test}). Ketiga metrik ini dipilih karena secara komprehensif mengukur aspek yang berbeda dari performa model regresi, yaitu rata-rata kesalahan absolut (MAE), sensitivitas terhadap kesalahan besar (RMSE), dan proporsi variansi yang dijelaskan model (R²).
2. Evaluasi Model Clustering: Evaluasi kualitas kluster yang dihasilkan oleh K-Means dilakukan menggunakan Silhouette Score yang dihitung menggunakan fungsi silhouette_score dari scikit-learn. Silhouette Score dihitung berdasarkan data clustering yang telah distandarisasi (X_{clustering_scaled}) dan label kluster yang dihasilkan oleh model K-Means. Nilai Silhouette Score yang dihasilkan kemudian diinterpretasikan untuk menilai seberapa baik setiap properti terkelompok ke dalam klasternya dibandingkan dengan kluster terdekat lainnya.

F. Deployment

Model terbaik yang dihasilkan pada tahap pemodelan disimpan menggunakan library joblib dalam format file .pkl untuk memungkinkan pemuatan ulang model tanpa perlu melatih ulang dari awal. Tiga file model disimpan yaitu rf_model.pkl untuk model Random Forest Regression, kmeans_model.pkl untuk model K-Means Clustering, dan scaler.pkl untuk objek StandardScaler yang digunakan dalam proses standardisasi data input. Ketiga file tersebut kemudian

diintegrasikan ke dalam aplikasi web interaktif yang dibangun menggunakan framework Streamlit, sehingga pengguna dapat melakukan prediksi harga properti secara real-time dan melihat hasil segmentasi properti melalui antarmuka yang intuitif dan mudah digunakan tanpa memerlukan pengetahuan teknis di bidang pemrograman.


IV. HASIL DAN PEMBAHASAN

A. Hasil Prediksi Harga Properti

1. Evaluasi Linear Regression

Model Linear Regression sebagai baseline dilatih menggunakan 1.168 data latih yang telah distandarisasi menggunakan StandardScaler. Setelah proses pelatihan selesai, model dievaluasi menggunakan 292 data uji untuk mengukur kemampuan generalisasinya terhadap data yang belum pernah dilihat sebelumnya. Hasil evaluasi menunjukkan bahwa model Linear Regression menghasilkan nilai MAE sebesar 25.414,73, yang berarti secara rata-rata prediksi model menyimpang sebesar \$25.414,73 dari harga aktual properti. Nilai RMSE yang diperoleh sebesar 39.763,30, lebih besar dibandingkan MAE, mengindikasikan adanya beberapa prediksi dengan kesalahan yang cukup besar dan konsisten dengan keberadaan outlier pada dataset.

Gbr 3. Distribusi Harga Jual Properti (SalePrice)



Nilai R^2 Score sebesar 0,79 menunjukkan bahwa model Linear Regression mampu menjelaskan 79% variansi SalePrice berdasarkan kelima fitur yang digunakan.

Performa Linear Regression yang cukup baik ini dapat dipahami mengingat beberapa fitur yang digunakan seperti GrLivArea dan TotalBsmtSF memiliki hubungan yang relatif linier terhadap SalePrice. Namun demikian, keterbatasan asumsi linieritas menyebabkan model tidak mampu menangkap pola-pola interaksi yang lebih kompleks antar fitur, yang pada akhirnya membatasi akurasi prediksi secara keseluruhan, terutama pada properti-properti dengan karakteristik yang berada di luar rentang nilai yang umum dalam dataset.

2. Evaluasi Random Forest Regression

Model Random Forest Regression dilatih menggunakan data latih yang sama dengan konfigurasi `random_state=42` dan `n_estimators=100`. Hasil evaluasi pada 292 data uji menunjukkan peningkatan performa yang signifikan dibandingkan model Linear Regression pada ketiga metrik evaluasi. Nilai MAE yang diperoleh sebesar 19.182,22

menunjukkan bahwa rata-rata kesalahan prediksi model lebih rendah sebesar \$6.232,51 dibandingkan Linear Regression. Nilai RMSE sebesar 28.922,58 juga menunjukkan penurunan yang signifikan sebesar \$10.840,72, mengindikasikan bahwa Random Forest lebih mampu menangani prediksi pada properti-properti dengan karakteristik yang ekstrem. Nilai R^2 Score sebesar 0,89 menunjukkan bahwa model mampu menjelaskan 89% variansi SalePrice, meningkat 10 poin persentase dibandingkan Linear Regression.

Peningkatan performa yang signifikan ini dapat dijelaskan oleh kemampuan Random Forest dalam membangun 100 decision tree secara paralel menggunakan mekanisme bootstrap aggregating, sehingga mampu menangkap pola hubungan nonlinier yang kompleks antara fitur-fitur properti dengan harga jualnya yang tidak dapat dimodelkan secara optimal oleh pendekatan linier.

3. Perbandingan Model

Perbandingan performa kedua model secara kuantitatif disajikan pada Tabel IV.

TABEL IV
PERBANDINGAN PERFORMA MODEL REGRESI

Model	MAE	RMSE	R^2 Score
Linear Regression	25.414,73	39.763,30	0,79
Random Forest Regression	19.182,22	28.922,58	0,89
Selisih	6.232,51	10.840,72	0,10
Peningkatan (%)	24,5%	27,3%	12,7%

Berdasarkan Tabel IV, Random Forest Regression secara konsisten mengungguli Linear Regression pada ketiga metrik evaluasi. Penurunan MAE sebesar 24,5% menunjukkan bahwa secara rata-rata kesalahan prediksi Random Forest lebih rendah hampir seperempat dibandingkan Linear Regression. Penurunan RMSE sebesar 27,3% yang lebih besar dari penurunan MAE mengindikasikan bahwa Random Forest juga lebih unggul dalam menangani prediksi pada data ekstrem dan outlier. Peningkatan R^2 Score sebesar 0,10 poin mencerminkan bahwa Random Forest mampu menjelaskan 10% variansi tambahan yang tidak dapat ditangkap oleh model linier. Hasil ini sejalan dengan penelitian Limbong et al. (2025) dalam JAIEA yang membuktikan bahwa Random Forest secara konsisten mengungguli Linear Regression dalam semua metrik evaluasi pada permasalahan prediksi harga properti [2], serta penelitian Adetunji et al. (2022) di Procedia Computer Science yang melaporkan nilai R^2 Random Forest sebesar 0,9 pada dataset perumahan yang serupa [3].

B. Hasil Clustering


1. Elbow Method

Penentuan jumlah kluster optimal dilakukan menggunakan Elbow Method dengan menghitung nilai WCSS

(Within-Cluster Sum of Squares) untuk berbagai nilai K mulai dari K=1 hingga K=10. Algoritma K-Means dijalankan dengan inisialisasi k-means++ dan parameter n_init=10 untuk setiap nilai K guna memastikan stabilitas hasil. Hasil perhitungan WCSS untuk setiap nilai K disajikan pada Tabel V.

TABEL V
NILAI WCSS UNTUK SETIAP NILAI K

Nilai K	WCSS	Penurunan WCSS
1	7.300,00	—
2	3.850,00	3.450,00
3	2.580,00	1.270,00
4	2.100,00	480,00
5	1.850,00	250,00
6	1.680,00	170,00



Berdasarkan grafik Elbow Method yang dihasilkan, penurunan nilai WCSS yang paling signifikan terjadi dari K=1 ke K=2 dan dari K=2 ke K=3. Setelah K=3, penurunan nilai WCSS mulai melandai secara signifikan sehingga penambahan jumlah kluster tidak lagi memberikan peningkatan kualitas pengelompokan yang sebanding dengan kompleksitas yang ditambahkan. Berdasarkan analisis ini, K=3 ditetapkan sebagai jumlah kluster optimal yang akan digunakan dalam pemodelan K-Means Clustering.

2. Silhouette Score

Evaluasi kualitas kluster yang dihasilkan oleh model K-Means dengan K=3 dilakukan menggunakan Silhouette Score. Hasil perhitungan menggunakan fungsi silhouette_score dari scikit-learn terhadap data clustering yang telah distandarisasi menunjukkan nilai Silhouette Score sebesar **0,30**. Nilai ini mengindikasikan bahwa kluster-kluster yang terbentuk memiliki struktur pengelompokan yang cukup bermakna, di mana sebagian besar properti telah ditempatkan pada kluster yang lebih sesuai dibandingkan kluster terdekat lainnya. Meskipun nilai 0,30 berada pada kategori

pengelompokan yang lemah hingga cukup menurut interpretasi standar Silhouette Score, hal ini dapat dipahami mengingat data properti yang digunakan memiliki distribusi yang tumpang tindih (overlapping) antar segmen harga, karena batas antar segmen properti di dunia nyata memang bersifat gradual dan tidak terpisah secara tegas. Temuan ini konsisten dengan penelitian Amin et al. (2024) dalam PeerJ Computer Science yang juga melaporkan tantangan serupa dalam clustering data properti akibat sifat distribusi data yang kontinu [5].


3. Karakteristik Cluster

Analisis karakteristik setiap kluster dilakukan dengan menghitung nilai rata-rata setiap fitur untuk masing-masing kluster. Hasil analisis karakteristik kluster disajikan secara lengkap pada Tabel VI.


TABEL VI
KARAKTERISTIK RATA-RATA SETIAP KLASTER

Fitur	Kluster 0	Kluster 1	Kluster 2
SalePrice (\$)	120.607,90	314.324,64	184.466,31
GrLivArea (sq ft)	1.120,52	2.171,97	1.616,61
OverallQual	4,92	8,09	6,39
GarageCars	1,14	2,66	1,98
TotalBsmtSF (sq ft)	819,19	1.623,89	1.057,25
Label Segmen	Properti Anggaran	Properti Premium	Properti Menengah

Gbr 5. Visualisasi K-Means Clustering Berdasarkan GrLivArea dan SalePrice



Gbr 6.Heatmap Karakteristik Rata-Rata Setiap Klaster Berdasarkan Fitur Terpilih



Berdasarkan Tabel VI, ketiga klaster yang terbentuk menunjukkan karakteristik yang berbeda secara signifikan dan dapat diinterpretasikan sebagai tiga segmen pasar properti yang berbeda sebagai berikut.

Klaster 0 — Properti Anggaran: Klaster ini terdiri dari properti-properti dengan harga jual rata-rata terendah sebesar \$120.607,90. Properti pada klaster ini memiliki luas hunian rata-rata sebesar 1.120,52 sq ft, nilai kualitas keseluruhan rata-rata sebesar 4,92 (dari skala 1–10), kapasitas garasi rata-rata 1,14 kendaraan, dan luas basement rata-rata sebesar 819,19 sq ft. Karakteristik ini mencerminkan properti dengan ukuran yang relatif kecil, kualitas bangunan yang sederhana, dan fasilitas pendukung yang terbatas, sehingga cocok untuk segmen pembeli dengan anggaran terbatas.


Klaster 1 — Properti Premium: Klaster ini merupakan segmen properti dengan harga jual rata-rata tertinggi sebesar \$314.324,64, hampir 2,6 kali lipat dibandingkan Klaster 0. Properti pada segmen ini memiliki luas hunian rata-rata tertinggi sebesar 2.171,97 sq ft, nilai kualitas keseluruhan rata-rata sebesar 8,09, kapasitas garasi rata-rata 2,66 kendaraan, dan luas basement rata-rata sebesar 1.623,89 sq ft. Kombinasi luas bangunan yang besar, kualitas konstruksi yang tinggi, dan fasilitas garasi yang memadai menjadikan properti pada klaster ini sebagai segmen premium yang ditargetkan untuk pembeli dengan daya beli tinggi.

Klaster 2 — Properti Kelas Menengah: Klaster ini menempati posisi tengah di antara kedua klaster lainnya dengan harga jual rata-rata sebesar \$184.466,31. Properti pada segmen ini memiliki luas hunian rata-rata 1.616,61 sq ft, nilai kualitas keseluruhan rata-rata 6,39, kapasitas garasi rata-rata 1,98 kendaraan, dan luas basement rata-rata 1.057,25 sq ft. Karakteristik yang berada di antara Klaster 0 dan Klaster 1 menjadikan segmen ini sebagai representasi properti kelas menengah yang merupakan segmen pasar terbesar dan paling banyak diminati di pasar perumahan secara umum.

C. Feature Importance

Analisis feature importance dilakukan untuk mengukur kontribusi relatif setiap fitur terhadap akurasi prediksi model Random Forest Regression.

Gbr 7.Feature Importance Model Random Forest Regression



Nilai importance diperoleh dari atribut `feature_importances_model` yang mengukur rata-rata penurunan impuritas (mean decrease in impurity) yang disumbangkan oleh setiap fitur di seluruh decision tree yang dibangun. Hasil lengkap feature importance disajikan pada Tabel VII.

TABEL VII
FEATURE IMPORTANCE RANDOM FOREST REGRESSION

Peringkat	Fitur	Nilai Importance	Kontribusi (%)
1	OverallQual	0,5825	58,25%
2	GrLivArea	0,2065	20,65%
3	TotalBsmtSF	0,1154	11,54%
4	YearBuilt	0,0633	6,33%
5	GarageCars	0,0324	3,24%
Total		1,0000	100,00%

1. OverallQual

OverallQual menempati peringkat pertama sebagai fitur paling dominan dengan nilai importance sebesar 0,5825, berkontribusi sebesar 58,25% terhadap akurasi prediksi model. Kontribusi yang sangat besar ini mengindikasikan bahwa persepsi kualitas keseluruhan sebuah properti, yang mencakup penilaian terhadap material bangunan, finishing, dan kondisi umum properti, merupakan faktor paling determinan dalam pembentukan harga jual. Hal ini secara intuitif logis karena pembeli properti cenderung bersedia membayar premium yang signifikan untuk properti dengan kualitas konstruksi yang lebih baik. Dominasi OverallQual yang sangat besar dengan selisih yang jauh terhadap fitur-fitur lainnya juga mengindikasikan bahwa peningkatan kualitas bangunan merupakan investasi paling efektif yang dapat dilakukan untuk meningkatkan nilai jual properti.

2. *GrLivArea*

GrLivArea menempati peringkat kedua dengan nilai importance sebesar 0,2065, berkontribusi sebesar 20,65% terhadap akurasi prediksi. Fitur ini merepresentasikan luas area hunian di atas tanah dalam satuan kaki persegi, yang secara langsung mencerminkan ukuran dan kapasitas ruang yang ditawarkan oleh sebuah properti. Kontribusi *GrLivArea* sebesar 20,65% mencerminkan bahwa luas bangunan merupakan faktor fisik terpenting setelah kualitas dalam menentukan nilai properti, konsisten dengan prinsip umum penilaian properti di mana harga cenderung meningkat secara proporsional dengan luas bangunan.

3. *GarageCars*

GarageCars menempati peringkat terakhir dengan nilai importance sebesar 0,0324, berkontribusi sebesar 3,24% terhadap akurasi prediksi. Meskipun memiliki kontribusi terkecil di antara kelima fitur, *GarageCars* tetap memberikan informasi yang relevan bagi model karena kapasitas garasi mencerminkan fasilitas pendukung dan kelas properti secara tidak langsung. Properti dengan kapasitas garasi yang lebih besar pada umumnya merupakan properti yang lebih luas dan lebih mahal, sehingga terdapat korelasi positif antara *GarageCars* dengan *SalePrice* meskipun kontribusi langsungnya terhadap model relatif kecil.

4. *TotalBsmtSF*

TotalBsmtSF menempati peringkat ketiga dengan nilai importance sebesar 0,1154, berkontribusi sebesar 11,54% terhadap akurasi prediksi. Fitur ini merepresentasikan total luas basement dalam satuan kaki persegi. Meskipun kontribusinya lebih kecil dibandingkan dua fitur teratas, basement yang luas dapat memberikan nilai tambah yang signifikan bagi sebuah properti karena dapat dimanfaatkan sebagai ruang tambahan multifungsi seperti ruang penyimpanan, ruang rekreasi, atau ruang kerja. Kontribusi *TotalBsmtSF* yang berada di posisi ketiga juga dapat dikaitkan dengan kecenderungan properti dengan basement yang luas untuk memiliki struktur bangunan yang lebih besar dan lebih mahal secara keseluruhan.

5. *YearBuilt*

YearBuilt menempati peringkat keempat dengan nilai importance sebesar 0,0633, berkontribusi sebesar 6,33% terhadap akurasi prediksi. Fitur ini merepresentasikan tahun pembangunan pertama kali properti tersebut didirikan. Kontribusi *YearBuilt* yang relatif lebih kecil namun tetap signifikan mencerminkan bahwa usia bangunan memengaruhi nilai properti melalui beberapa mekanisme, di antaranya kondisi fisik bangunan yang semakin menurun seiring waktu, kepatuhan terhadap standar konstruksi yang berbeda antar era pembangunan, serta nilai historis atau arsitektural yang dimiliki oleh properti-properti yang lebih tua.

D. *Pembahasan Hasil*

Secara keseluruhan, hasil penelitian ini menunjukkan bahwa kombinasi Random Forest Regression untuk prediksi

harga dan K-Means Clustering untuk segmentasi properti memberikan hasil yang saling melengkapi dan komprehensif dalam menganalisis dataset House Prices Kaggle.

Dari perspektif prediksi harga, Random Forest Regression terbukti secara signifikan lebih unggul dibandingkan Linear Regression dengan peningkatan R^2 Score dari 0,79 menjadi 0,89, penurunan MAE sebesar 24,5%, dan penurunan RMSE sebesar 27,3%. Keunggulan ini secara fundamental berakar pada kemampuan ensemble learning Random Forest yang membangun 100 decision tree secara paralel dan menggabungkan prediksinya, sehingga mampu menangkap hubungan nonlinier yang kompleks antara karakteristik fisik properti dengan harga jualnya yang tidak dapat dimodelkan secara optimal oleh pendekatan linier [3]. Nilai R^2 sebesar 0,89 yang diperoleh juga mendekati nilai yang dilaporkan oleh Adetunji et al. (2022) sebesar 0,9 [3], mengkonfirmasi bahwa implementasi Random Forest dalam penelitian ini telah berhasil dijalankan dengan baik.

Dari perspektif feature importance, dominasi OverallQual dengan kontribusi 58,25% memberikan implikasi praktis yang penting bagi pelaku pasar properti. Temuan ini mengindikasikan bahwa investasi dalam peningkatan kualitas bangunan seperti renovasi material, peningkatan finishing, dan pembaruan fasilitas merupakan strategi paling efektif untuk meningkatkan nilai jual properti secara signifikan. Sementara itu, *GrLivArea* dengan kontribusi 20,65% menegaskan bahwa luas bangunan tetap menjadi pertimbangan utama kedua dalam penilaian properti. Secara kumulatif, dua fitur teratas berkontribusi sebesar 78,90% terhadap akurasi model, menegaskan bahwa kualitas dan luas bangunan merupakan dua dimensi paling kritis dalam ekosistem penilaian properti. Temuan ini konsisten dengan hasil penelitian Wardani et al. (2024) yang menemukan bahwa dimensi bangunan merupakan faktor dominan dalam menentukan harga properti di Surabaya [1].

Dari perspektif segmentasi, K-Means dengan $K=3$ berhasil mengidentifikasi tiga segmen pasar properti yang berbeda secara signifikan yaitu Properti Anggaran (rata-rata \$120.607), Properti Kelas Menengah (rata-rata \$184.466), dan Properti Premium (rata-rata \$314.324). Perbedaan harga rata-rata antara segmen terendah dan tertinggi mencapai \$193.717 atau sekitar 2,6 kali lipat, mencerminkan stratifikasi pasar properti yang cukup jelas. Meskipun nilai Silhouette Score sebesar 0,30 berada pada kategori cukup, hal ini dapat dipahami mengingat sifat alami data properti yang memiliki distribusi kontinu tanpa batas segmen yang tegas. Informasi segmentasi ini memiliki nilai praktis yang tinggi bagi investor dan pelaku bisnis properti dalam mengidentifikasi segmen target, menetapkan strategi harga, dan memahami positioning produk properti mereka di pasar.


Secara keseluruhan, integrasi kedua pendekatan ini dalam satu sistem terpadu berbasis Streamlit memberikan nilai tambah yang komprehensif, di mana pengguna tidak hanya dapat memperoleh estimasi harga properti yang akurat tetapi juga dapat memahami posisi properti tersebut dalam konteks segmen pasar yang lebih luas.

V. IMPLEMENTASI SISTEM

A. Arsitektur Sistem

Sistem prediksi harga dan segmentasi properti yang dibangun dalam penelitian ini mengadopsi arsitektur berbasis web yang terdiri atas tiga lapisan utama sebagaimana digambarkan pada Gambar 8.

Gbr 8. Arsitektur Sistem Aplikasi



Lapisan pertama adalah Data Layer, yang mencakup dataset House Prices dari Kaggle dalam format CSV dan tiga file model yang telah disimpan menggunakan joblib yaitu `rf_model.pkl` (model Random Forest Regression), `kmeans_model.pkl` (model K-Means Clustering), dan `scaler.pkl` (objek StandardScaler untuk standardisasi input). Ketiga file model ini dimuat ke dalam memori aplikasi pada saat aplikasi pertama kali dijalankan, sehingga proses prediksi dapat dilakukan secara real-time tanpa perlu melatih ulang model dari awal.

Lapisan kedua adalah Processing Layer, yang terdiri atas modul-modul pemrosesan data dan inferensi model. Modul ini bertanggung jawab untuk menerima input dari pengguna, melakukan preprocessing menggunakan scaler yang telah dimuat, mengeksekusi prediksi menggunakan model yang sesuai, serta memformat dan mempersiapkan hasil untuk ditampilkan kepada pengguna.

Lapisan ketiga adalah Presentation Layer, yang diimplementasikan sepenuhnya menggunakan framework Streamlit. Lapisan ini bertanggung jawab untuk merender antarmuka web yang interaktif, menerima input dari pengguna melalui berbagai komponen seperti slider dan number input, serta menampilkan hasil prediksi dan visualisasi dalam format yang mudah dipahami. Streamlit dipilih karena kemampuannya mengintegrasikan ketiga lapisan ini dalam satu file Python tanpa memerlukan infrastruktur backend-frontend yang terpisah.


B. Implementasi Streamlit

Aplikasi web dibangun menggunakan framework Streamlit dengan navigasi multi-halaman yang terdiri atas lima halaman

utama. Setiap halaman dirancang untuk memenuhi kebutuhan pengguna yang berbeda-beda mulai dari eksplorasi data hingga prediksi dan visualisasi interaktif.

1. Halaman Home


Gbr 9. Tampilan Halaman Home




Halaman Home merupakan halaman pertama yang ditampilkan ketika pengguna mengakses aplikasi. Halaman ini berfungsi sebagai halaman sambutan yang memberikan gambaran umum tentang tujuan dan fitur-fitur utama aplikasi kepada pengguna. Konten pada halaman ini mencakup judul aplikasi, deskripsi singkat tentang sistem prediksi harga dan segmentasi properti yang dibangun, serta penjelasan tentang dataset dan metodologi yang digunakan. Navigasi menuju halaman-halaman lain juga tersedia dari halaman ini melalui sidebar menu yang disediakan oleh Streamlit. Desain halaman Home dirancang untuk memberikan kesan pertama yang informatif dan ramah pengguna, sehingga pengguna baru dapat langsung memahami tujuan dan cara penggunaan aplikasi tanpa memerlukan panduan tambahan.

2. Halaman Dataset Overview

Gbr 10. Tampilan Informasi Umum Dataset (Tab Info)




Gbr 11. Ringkasan Statistik Deskriptif (Tab Statistics)



Gbr 12. Visualisasi Distribusi Harga dan Korelasi Fitur (Tab Distributions)



Gbr 13. Matrics Korelasi antar Fitur (Tab Correlations)




Halaman Dataset Overview dirancang untuk memberikan gambaran komprehensif tentang dataset yang digunakan kepada pengguna. Pada halaman ini ditampilkan preview data dalam bentuk tabel interaktif yang dapat di-scroll dan diurutkan, informasi dimensi dataset (1.460 baris $\times$ 81 kolom), statistik deskriptif setiap fitur yang mencakup nilai minimum, maksimum, rata-rata, dan standar deviasi, serta visualisasi distribusi dan korelasi antar fitur. Halaman ini juga menampilkan informasi tentang missing value yang ada pada dataset dan bagaimana penanganannya dilakukan dalam proses data preparation. Tersedianya halaman Dataset Overview memungkinkan pengguna untuk memperoleh pemahaman yang lebih mendalam tentang karakteristik data yang mendasari model prediksi, sehingga dapat

menginterpretasikan hasil prediksi dengan lebih tepat dan kontekstual.

3. Halaman Prediction

Gbr 14. Tampilan Prediksi Harga Properti



Halaman Prediction merupakan halaman inti dari aplikasi yang memungkinkan pengguna untuk melakukan prediksi harga properti secara real-time berdasarkan input karakteristik properti yang dimasukkan. Halaman ini dirancang dengan mempertimbangkan kemudahan penggunaan, sehingga pengguna tanpa latar belakang teknis sekalipun dapat mengoperasikannya secara intuitif tanpa memerlukan panduan tambahan.

Antarmuka halaman ini menyediakan komponen input interaktif untuk kelima fitur yang digunakan dalam model. OverallQual disediakan dalam bentuk slider dengan rentang nilai 1 hingga 10, di mana setiap nilai merepresentasikan tingkat kualitas keseluruhan material dan finishing bangunan dari yang terendah hingga tertinggi. GrLivArea disediakan dalam bentuk number input dalam satuan kaki persegi yang memungkinkan pengguna memasukkan luas area hunian di atas tanah secara presisi. GarageCars disediakan dalam bentuk slider dengan rentang 0 hingga 4 yang merepresentasikan kapasitas kendaraan yang dapat ditampung oleh garasi properti. TotalBsmtSF disediakan dalam bentuk number input dalam satuan kaki persegi untuk memasukkan total luas basement properti. YearBuilt disediakan dalam bentuk slider dengan rentang tahun yang disesuaikan dengan rentang tahun pembangunan properti dalam dataset, yaitu dari tahun 1872 hingga 2010.

Setelah pengguna mengisi seluruh nilai input dan menekan tombol *Predict*, sistem secara otomatis menjalankan serangkaian proses di balik layar. Pertama, nilai input yang dimasukkan pengguna dikemas dalam bentuk array numpy dan distandarisasi menggunakan objek StandardScaler yang telah dimuat dari file scaler.pkl, sehingga skala input sesuai dengan skala data latih yang digunakan saat pelatihan model. Kedua, array yang telah distandarisasi tersebut diumpungkan ke model Random Forest Regression yang dimuat dari file rf_model.pkl untuk menghasilkan prediksi harga properti dalam satuan dolar Amerika Serikat. Ketiga, secara bersamaan array input yang sama juga diumpungkan ke model K-Means Clustering yang dimuat dari file kmeans_model.pkl untuk menentukan segmen klaster dari properti yang diinputkan.


Hasil prediksi kemudian ditampilkan kepada pengguna dalam dua informasi utama. Pertama, estimasi harga properti yang ditampilkan dalam format mata uang yang mudah dibaca disertai dengan keterangan rentang harga wajar berdasarkan karakteristik input yang diberikan. Kedua, label segmen pasar properti yang terdiri atas tiga kemungkinan yaitu Properti Anggaran, Properti Kelas Menengah, atau Properti Premium, disertai dengan deskripsi singkat karakteristik segmen tersebut sehingga pengguna dapat memahami posisi properti yang diinputkan dalam konteks pasar yang lebih luas. Kombinasi kedua informasi ini memungkinkan pengguna tidak hanya mengetahui estimasi harga secara numerik, tetapi juga memperoleh pemahaman kontekstual tentang segmen pasar dari properti yang sedang dievaluasi.

4. Halaman Visualization


Gbr 15. Visualisasi Model Performance (Tab Model Performance)



Gbr 16. Visualisasi Cluster Analysis (Tab Cluster Analysis)




Gbr 17. Visualisasi Elbow Metode (Tab Elbow Metode)



Halaman Visualization menyediakan berbagai visualisasi interaktif yang membantu pengguna dalam memahami pola dan struktur data properti secara lebih mendalam. Visualisasi yang tersedia pada halaman ini mencakup: (a) grafik distribusi SalePrice dalam bentuk histogram dengan kurva KDE yang menampilkan nilai mean dan median; (b) heatmap korelasi antar fitur numerik dataset; (c) scatter plot hubungan antara fitur-fitur utama dengan SalePrice; (d) grafik Elbow Method yang menampilkan nilai WCSS untuk K=1 hingga K=10; (e) visualisasi hasil clustering dalam bentuk scatter plot dua dimensi dengan pewarnaan berdasarkan label kluster menggunakan fitur GrLivArea dan SalePrice sebagai sumbu; (f) heatmap karakteristik rata-rata setiap kluster; dan (g) grafik batang feature importance yang menampilkan kontribusi persentase setiap fitur terhadap akurasi model Random Forest.

5. Halaman About

Gbr 16. Tampilan Halaman About



Halaman About menyediakan informasi tentang penelitian dan pengembang aplikasi. Halaman ini mencantumkan informasi mengenai latar belakang penelitian, identitas peneliti beserta afiliasi institusional dari Program Studi Sistem Informasi Universitas Negeri Surabaya, penjelasan tentang metodologi CRISP-DM yang digunakan, serta informasi tentang teknologi dan library Python yang digunakan dalam pembangunan sistem yaitu scikit-learn untuk pemodelan

machine learning, pandas dan numpy untuk pemrosesan data, matplotlib dan seaborn untuk visualisasi, joblib untuk penyimpanan model, dan Streamlit sebagai framework aplikasi web.

C. Pengujian Sistem

Pengujian sistem dilakukan untuk memverifikasi bahwa seluruh komponen aplikasi berfungsi dengan benar dan menghasilkan output yang konsisten dengan hasil pemodelan di notebook. Pengujian dilaksanakan melalui tiga skenario sebagai berikut.

Skenario 1 — Pengujian Prediksi Harga: Pengujian dilakukan dengan memasukkan nilai input yang merepresentasikan karakteristik tiga tipe properti yang berbeda yaitu properti anggaran, menengah, dan premium, kemudian membandingkan output aplikasi dengan hasil prediksi yang dihitung secara manual menggunakan model yang sama. Hasil pengujian menunjukkan bahwa output aplikasi konsisten dengan hasil prediksi model, mengkonfirmasi bahwa proses loading model, standarisasi input, dan inferensi model berjalan dengan benar. Sebagai contoh, input properti dengan OverallQual=7, GrLivArea=1.710, GarageCars=2, TotalBsmtSF=856, dan YearBuilt=2003 menghasilkan prediksi harga yang konsisten dengan nilai aktual pada dataset yaitu \$208.500.

Skenario 2 — Pengujian Segmentasi: Pengujian segmentasi dilakukan dengan memverifikasi bahwa label klaster yang dihasilkan oleh aplikasi untuk setiap input properti konsisten dengan label klaster yang dihasilkan oleh model K-Means di notebook. Pengujian menggunakan sampel properti dari masing-masing klaster dan memverifikasi bahwa aplikasi mengklasifikasikannya ke dalam segmen yang tepat. Hasil pengujian menunjukkan konsistensi penuh antara output aplikasi dengan hasil clustering di notebook untuk seluruh sampel yang diuji.

Skenario 3 — Pengujian Visualisasi: Pengujian visualisasi dilakukan dengan memverifikasi bahwa seluruh grafik dan chart pada halaman Visualization ditampilkan dengan benar dan menampilkan data yang akurat sesuai dengan dataset yang digunakan. Pengujian mencakup verifikasi nilai statistik yang ditampilkan pada grafik distribusi, akurasi nilai pada heatmap korelasi, serta kesesuaian visualisasi hasil clustering dengan data aktual. Seluruh visualisasi berhasil ditampilkan dengan benar dan menampilkan informasi yang akurat dan konsisten dengan hasil analisis di notebook.

Secara keseluruhan, hasil pengujian sistem menunjukkan bahwa seluruh komponen aplikasi berfungsi dengan baik dan menghasilkan output yang akurat, konsisten, dan informatif. Aplikasi berhasil mengintegrasikan model prediksi harga dan segmentasi properti dalam satu antarmuka web yang interaktif dan mudah digunakan oleh pengguna akhir tanpa memerlukan pengetahuan teknis di bidang data science maupun pemrograman.

VI. KESIMPULAN

A. Kesimpulan

Berdasarkan hasil penelitian yang telah dilaksanakan menggunakan metodologi CRISP-DM pada dataset House

Prices dari Kaggle, dapat ditarik beberapa kesimpulan sebagai berikut.

Pertama, model prediksi harga properti berhasil dibangun menggunakan algoritma Random Forest Regression dengan memanfaatkan lima fitur utama yaitu OverallQual, GrLivArea, GarageCars, TotalBsmtSF, dan YearBuilt. Model yang dibangun menunjukkan performa yang baik dengan nilai MAE sebesar 19.182,22, RMSE sebesar 28.922,58, dan R^2 Score sebesar 0,89, yang berarti model mampu menjelaskan 89% variansi harga jual properti berdasarkan kelima fitur tersebut.

Kedua, perbandingan antara Random Forest Regression dan Linear Regression menunjukkan bahwa Random Forest Regression secara konsisten mengungguli Linear Regression pada ketiga metrik evaluasi yang digunakan. Random Forest menghasilkan penurunan MAE sebesar 24,5% dan penurunan RMSE sebesar 27,3% dibandingkan Linear Regression, mengkonfirmasi bahwa algoritma berbasis ensemble lebih efektif dalam menangkap hubungan nonlinier yang kompleks antara karakteristik fisik properti dengan harga jualnya.

Ketiga, analisis feature importance menunjukkan bahwa OverallQual merupakan fitur paling dominan dengan kontribusi sebesar 58,25% terhadap akurasi prediksi model, diikuti oleh GrLivArea sebesar 20,65%, TotalBsmtSF sebesar 11,54%, YearBuilt sebesar 6,33%, dan GarageCars sebesar 3,24%. Secara kumulatif, dua fitur teratas berkontribusi sebesar 78,90% terhadap akurasi model, menegaskan bahwa kualitas dan luas bangunan merupakan dua dimensi paling kritis dalam penilaian properti.

Keempat, segmentasi properti menggunakan algoritma K-Means Clustering dengan Elbow Method berhasil mengidentifikasi K=3 sebagai jumlah klaster optimal dan menghasilkan tiga segmen pasar properti yang berbeda secara signifikan, yaitu Properti Anggaran dengan rata-rata harga \$120.607,90, Properti Kelas Menengah dengan rata-rata harga \$184.466,31, dan Properti Premium dengan rata-rata harga \$314.324,64. Kualitas klaster yang dihasilkan memperoleh nilai Silhouette Score sebesar 0,30 yang mencerminkan pengelompokan yang cukup bermakna mengingat sifat distribusi data properti yang kontinu dan gradual.

Kelima, model terbaik berhasil diimplementasikan ke dalam aplikasi web interaktif berbasis Streamlit yang terdiri atas lima halaman utama yaitu Home, Dataset Overview, Prediction, Visualization, dan About. Hasil pengujian sistem menunjukkan bahwa seluruh komponen aplikasi berfungsi dengan baik, menghasilkan output prediksi dan segmentasi yang akurat dan konsisten dengan hasil pemodelan di notebook, serta dapat digunakan secara langsung oleh pengguna tanpa memerlukan pengetahuan teknis di bidang data science.

B. Saran

Berdasarkan hasil dan keterbatasan penelitian yang telah dilaksanakan, beberapa saran untuk pengembangan penelitian selanjutnya adalah sebagai berikut.

Pertama, penelitian selanjutnya dapat memperluas jumlah fitur yang digunakan dalam pemodelan dengan

mempertimbangkan seluruh 81 atribut yang tersedia pada dataset, atau menerapkan metode seleksi fitur yang lebih canggih seperti Recursive Feature Elimination (RFE) atau metode berbasis permutation importance untuk mengidentifikasi kombinasi fitur yang paling optimal secara otomatis.

Kedua, eksplorasi terhadap algoritma machine learning lain yang lebih advanced seperti Gradient Boosting, XGBoost, atau LightGBM dapat dilakukan untuk membandingkan performa dengan Random Forest Regression dan berpotensi menghasilkan akurasi prediksi yang lebih tinggi, mengingat algoritma-algoritma tersebut telah terbukti menghasilkan performa yang sangat kompetitif pada berbagai permasalahan regresi.

Ketiga, kualitas segmentasi dapat ditingkatkan dengan mengeksplorasi algoritma clustering alternatif seperti DBSCAN atau Hierarchical Clustering yang tidak memerlukan penentuan jumlah kluster secara manual dan lebih robust terhadap distribusi data yang tidak beraturan, sehingga berpotensi menghasilkan nilai Silhouette Score yang lebih tinggi dibandingkan K-Means.

Keempat, penerapan teknik hyperparameter tuning yang lebih sistematis menggunakan GridSearchCV atau RandomizedSearchCV dapat dilakukan untuk mengoptimalkan parameter model Random Forest Regression seperti `n_estimators`, `max_depth`, `min_samples_split`, dan `min_samples_leaf`, sehingga potensi akurasi model dapat dimaksimalkan secara lebih terstruktur.

Kelima, pengembangan aplikasi dapat ditingkatkan dengan menambahkan fitur penyimpanan riwayat prediksi, integrasi dengan data properti real-time dari platform listing properti, serta pengembangan versi mobile yang lebih aksesibel, sehingga nilai praktis sistem bagi pengguna akhir dapat ditingkatkan secara signifikan.

REFERENSI

- [1] A. Wardani, H. Irawan, M. Syah, M. Akmal, N. Nariwari, and K. M. Hindrayani, "Analisis dan Prediksi Harga Properti Rumah di Kota Surabaya dengan Algoritma Random Forest," *Prosiding Seminar Nasional Sains Data (SENADA)*, vol. 4, no. 1, pp. 885–894, Oct. 2024. doi: 10.33005/senada.v4i1.375.
- [2] H. Limbong, M. A. Lubis, and Mhd. Furqan, "House Price Prediction Analysis Using Linear Regression and Random Forest Algorithms," *Journal of Artificial Intelligence and Engineering Applications (JAIEA)*, vol. 4, no. 3, pp. 1928–1933, 2025. doi: 10.59934/jaiea.v4i3.1047.
- [3] A. B. Adetunji, O. N. Akande, F. A. Ajala, O. Oyewo, Y. F. Akande, and G. Oluwadara, "House Price Prediction using Random Forest Machine Learning Technique," *Procedia Computer Science*, vol. 199, pp. 806–813, 2022. doi: 10.1016/j.procs.2022.01.100.
- [4] J. Yu, "Prediction on Housing Price Based on the Data on Kaggle," in *Proc. 3rd International Conference on E-Commerce and Internet Technology (ECIT 2022)*, Atlantis Highlights in Engineering, vol. 11, pp. 627–634, 2023. doi: 10.2991/978-94-6463-005-3_64.
- [5] M. M. Amin, N. S. Sani, M. F. Nasrudin, S. Abdullah, A. Chhabra, and F. A. Kadir, "Clustering analysis for classifying fake real estate listings," *PeerJ Computer Science*, vol. 10, e2019, Jun. 2024. doi: 10.7717/peerj-cs.2019.
- [6] A. Punhani, N. Faujdar, K. K. Mishra, and M. Subramanian, "Binning-Based Silhouette Approach to Find the Optimal Cluster Using K-Means," *IEEE Access*, vol. 10, pp. 115025–115032, Oct. 2022. doi: 10.1109/ACCESS.2022.3215568.
- [7] A. M. Shimaoka, R. C. Ferreira, and A. Goldman, "The Evolution of CRISP-DM for Data Science: Methods, Processes and Frameworks,"

SBC Computing Reviews, vol. 4, no. 1, pp. 28–43, 2024. doi: 10.5753/reviews.2024.3757.

- [8] H. Hakim, D. Kamil, and B. Alatas, "Pendekatan Machine Learning untuk Estimasi Harga Rumah dengan Regresi Linier," *ALPHA: Journal of Science and Technology*, vol. 1, no. 1, pp. 18–22, 2025. doi: 10.70716/alpha.v1i1.99.
- [9] A. Fauzi, N. Maulidah, R. Supriyadi, H. Nalatissifa, and S. Diantika, "Prediksi Harga Properti Di Indonesia Menggunakan Algoritma Random Forest," *RIGGS: Journal of Artificial Intelligence and Digital Business*, vol. 2, no. 1, 2025. doi:10.31004/riggs.v4i1.367
- [10] S. Emilita, P. S. Rahayu, S. R. Larasati, G. Taufiq, and J. T. Kumalasari, "Penerapan Algoritma Random Forest Dalam Memprediksi Harga Properti di Jakarta Selatan Berdasarkan Karakteristik Fisik dan Lokasi," *Jurnal Minfo Polgan*, vol. 14, no. 2, pp. 3415–3421, 2026. doi: 10.33395/jmp.v14i2.15735.

LAMPIRAN

Dataset

<https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques>

Aplikasi

<https://house-price-prediction-and-property-segmentation.streamlit.app/>

Video Presentasi

<https://youtu.be/Z60aDSw3UUI>

Source Code

<https://github.com/ENRIST/house-price-prediction-and-property-segmentation.git>

Repository Project

<https://github.com/ENRIST/house-price-prediction-and-property-segmentation.git>